

TEORÍA DE ALGORITMOS
(75.29) CURSO BUCHWALD - GENENDER

Trabajo Práctico 3



Fecha de entrega: 24/11/2023

- Gauler, Ian Benjamin, Padrón: 109437
- Jauregui, Melina Belén, Padrón: 109524
- Tourne Passarino, Patricio, Padrón: 108725

Índice

1	Introducción	3
1.1	Información de la problemática	3
2	Análisis de la complejidad del problema	3
3	Hitting-Set Problem: Un Problema NP-Completo	4
3.1	Reducción Vertex Cover a Dominating-Set Problem	4
3.1.1	Ejemplos:	5
3.2	Reducción Dominating-Set a Hitting-Set	5
3.2.1	Ejemplos:	6
3.3	Reducción Set-Cover a Hitting-Set	7
3.3.1	Ejemplos:	8
4	Solución por backtracking	8
5	Solución por Programación Lineal	10
5.1	Programación Lineal Entera	10
5.2	Aproximación por Programación Lineal Continua	11
6	Aproximación por Greedy	12
6.0.1	Máximo por grupo	12
6.0.2	Máximo global con recálculo	13
7	Ejemplos	14
8	Mediciones	16
9	Conclusiones	17

1. Introducción

El propósito de este informe radica en llevar a cabo un análisis de los distintos enfoques y diseños aplicados para abordar la problemática presentada por Scaloni. Este desafío se centra en la determinación del conjunto mínimo de jugadores, denotado como C , requerido para satisfacer las demandas de cada medio, asegurando al menos la presencia de un jugador favorito por cada uno. Es importante destacar que este problema se enmarca como un caso específico del 'Hitting Set Problem'. En consecuencia, a lo largo de este informe, se realizará un análisis de múltiples soluciones con el fin de resolver este último.

1.1. Información de la problemática

El enunciado propuesto, nos da la siguiente información:

- Scaloni tiene a su disposición el conjunto A de $n = 43$ jugadores a_1, a_2, \dots, a_{43} .
- Existen m medios, cada uno con un grupo de jugadores favorito B_1, B_2, \dots, B_m , ($B_i \in A \forall i$)
- Se quiere el subconjunto $C \in A$ de menor tamaño tal que C tenga al menos un elemento de cada B_i (es decir, $C \cap B_i$)
- Scaloni necesita obtener el grupo C más pequeño de jugadores de tal forma que cada medio B_i tenga al menos un jugador en el equipo.

2. Análisis de la complejidad del problema

El problema planteado por Scaloni es un caso específico del problema del Hitting-Set, cuya definición formal se presenta de la siguiente manera: dado un conjunto A compuesto por n elementos y m subconjuntos B_1, B_2, \dots, B_m pertenecientes a A ($B_i \subseteq A \forall i \in \mathbb{N}_m$), se busca encontrar un conjunto $C \subseteq A$ tal que para cada subconjunto B_j , donde $B_j \subseteq A \forall j \in \mathbb{N}_m$, $C \cap B_j \neq \emptyset$.

Además de su formulación básica, el problema del Hitting-Set también presenta una versión de decisión: dada la colección de un conjunto A con n elementos y m subconjuntos B_1, B_2, \dots, B_m ($B_i \subseteq A$ para todo i), junto con un parámetro numérico k , se plantea el interrogante sobre la existencia de un conjunto $C \subseteq A$ que cumpla con dos condiciones fundamentales:

- En primer lugar, que la cardinalidad de C sea menor o igual a k ($|C| \leq k$)
- En segundo lugar, que para cada subconjunto B_j , la intersección entre C y B_j no sea vacía ($C \cap B_j \neq \emptyset$) para todo j perteneciente al conjunto de números naturales hasta m .

Para realizar esta verificación, se llevan a cabo dos operaciones clave que definen la complejidad del proceso. La primera operación, relacionada con la verificación de la cardinalidad de C ($|C| \leq k$), tiene una complejidad constante $O(1)$, ya que implica simplemente obtener el número de elementos en C y verificar que $|C| \leq k$. La segunda operación, que implica verificar la inclusión de al menos un elemento de C en cada conjunto B_j , presenta una complejidad de $O(n \times m)$. Esto se debe a que para cada conjunto B_j (j perteneciente al conjunto de números naturales hasta m) (operación $O(m)$), se debe recorrer, en el peor de los casos, todo el conjunto C ($O(n)$) para verificar la pertenencia de al menos un elemento de este en B_j (operación con complejidad $O(1)$ si tanto B_j como C se implementan como un 'set').

De esta manera, el problema del Hitting-Set se sitúa en la clase de complejidad NP debido a su capacidad de verificación en tiempo polinomial.

3. Hitting-Set Problem: Un Problema NP-Completo

La clasificación del problema del Hitting-Set como NP-Completo se establece mediante la demostración de su reducibilidad polinómica a partir de otros problemas ya catalogados como NP-Completo.

En nuestro análisis, nos hemos propuesto abordar esta demostración de dos maneras distintas, empleando estrategias de reducción que ilustran la naturaleza NP-Completa del Hitting-Set Problem:

- Reducción de Vertex Cover a Dominating-Set Problem \rightarrow Reducción de Dominating-Set Problem a Hitting-Set Problem.
- Reducción de Set Cover a Hitting-Set Problem.

Es importante destacar que la pertenencia de Vertex Cover y Set Cover a NP-Completo fue demostrada en clases anteriores.

- Vertex Cover <https://youtu.be/i8qhWUMC50U?si=SjlPNHUKohR-az5p&t=5100>
- Set Cover <https://youtu.be/ZvXVKWyBryg?si=BHp7N4ueTkT7QpSG&t=8707>

3.1. Reducción Vertex Cover a Dominating-Set Problem

- Vertex Cover: Dado un grafo $G = (V, E)$, donde V es un conjunto de vértices y E es un conjunto de aristas, un Vertex Cover de G es un conjunto $C \subseteq V$ tal que para cada arista (u, v) en E , al menos uno de los extremos, u o v , pertenece al conjunto C .
- Dominating Set: Dado un grafo G , se busca un conjunto mínimo de vértices C tal que, para todo vértice $v \in G$, esté contenido en C o existe al menos un vértice en C adyacente de v .

La reducción Vertex-Cover \leq_p Dominating-Set consta en lo siguiente: Dado del grafo G con n vértices y m aristas del problema Vertex Cover, para cada par de vértices adyacentes $v - w$, se agregan ambos al grafo G' (del problema Dominating Set) junto a su arista y se agrega un tercer vértice auxiliar vw , adyacente a los otros dos. A será el conjunto de vértices auxiliares.

Luego, del conjunto V' de k vértices solución de Dominating Set, se debe agregar a V (solución de Vertex Cover) todos los vértices de V' que no estén en el conjunto de auxiliares y, para cada vértice en $V' \cap A$ se agrega a V cualquiera de sus adyacentes. La primera parte de la reducción es $O(m)$ y la segunda es $O(k)$, $k \leq n$, por lo que la complejidad total es $O(m + k)$, que es polinomial.

$$\text{Vertex-Cover} \leq_p \text{Dominating-Set}$$

3.1.1. Ejemplos:

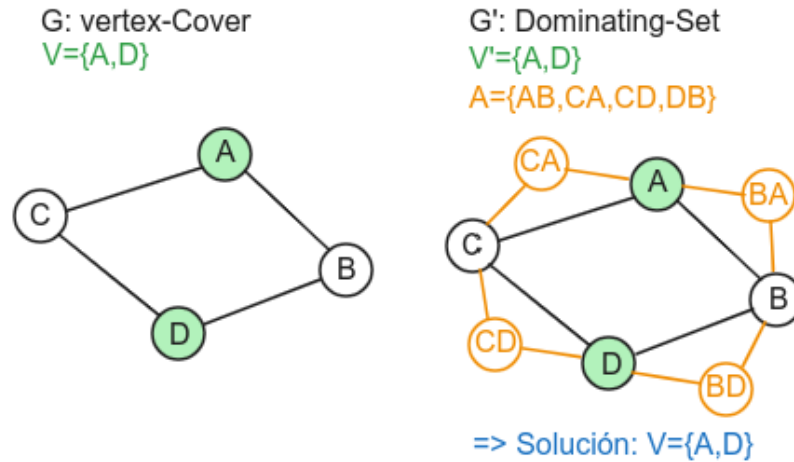


Figura 1: Ejemplo de reducción de Vertex-Cover a Dominating-Set

Si ahora, queremos un Vertex-Cover de hasta 3 vértices ($k = 3$), luego la solución proporcionada por Dominating Set puede ser la siguiente:

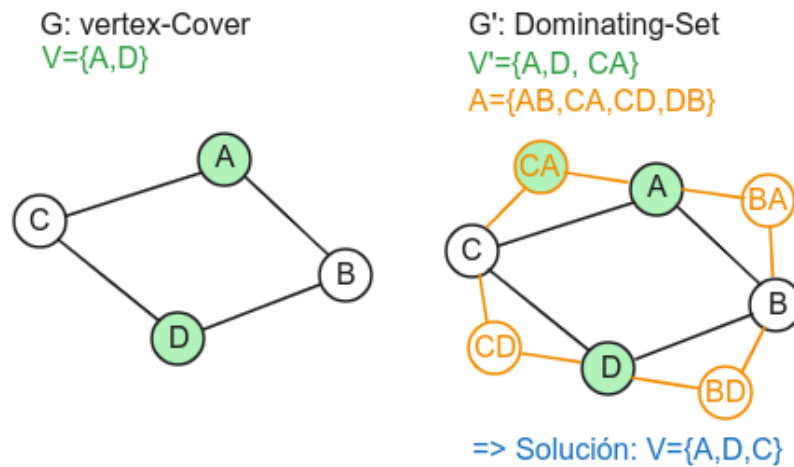


Figura 2: Ejemplo de reducción de Vertex-Cover a Dominating-Set

Notar que el conjunto solución de Dominating-Set $V' = \{CA, A, D\}$ incluye un vértice que pertenece al conjunto de auxiliares $CA \in A$. Por ello, se debe agregar a V cualquiera de sus adyacentes, en este caso C .

3.2. Reducción Dominating-Set a Hitting-Set

La reducción Dominating-Set \leq_p Hitting-Set consta en lo siguiente: Dado un grafo G de n vértices del problema Dominating Set, para cada vértice v_i , se construye un grupo B_i con él mismo y todos sus vértices adyacentes. Esto tiene un costo temporal de $O(N \times E)$, ya que para cada vértice v_i se deben obtener los vértices adyacentes a v_i y crear los conjuntos B_i por cada uno de ellos. De esta manera, realizamos operaciones polinomiales para transformar nuestro problema de Dominating-Set a Hitting-Set.

A su vez, esta reducción se caracteriza por ser de equivalencia simple ya que el resultado devuelto por el algoritmo de Hitting Set coincide directamente con los resultados esperados por el algoritmo de Dominating Set. Como consecuencia, no es necesario realizar operaciones adicionales o suplementarias para obtener el resultado deseado.

$$\text{Dominating-Set} \leq_p \text{Hitting-Set}$$

3.2.1. Ejemplos:

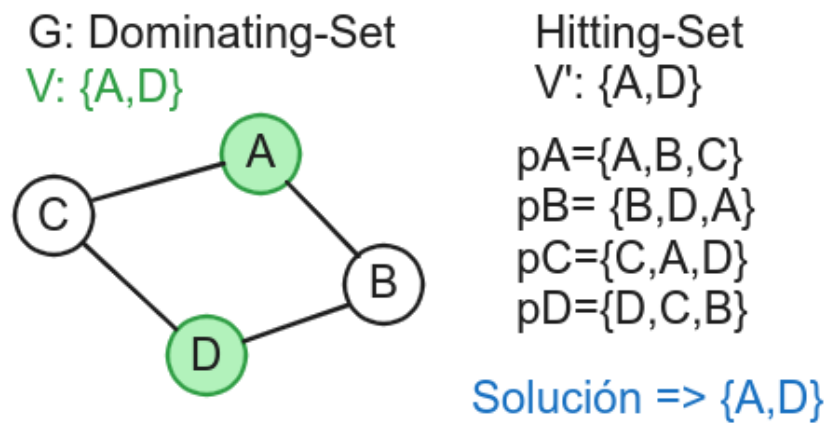


Figura 3: Ejemplo 1 de reducción de Dominating-Set a Hitting Set

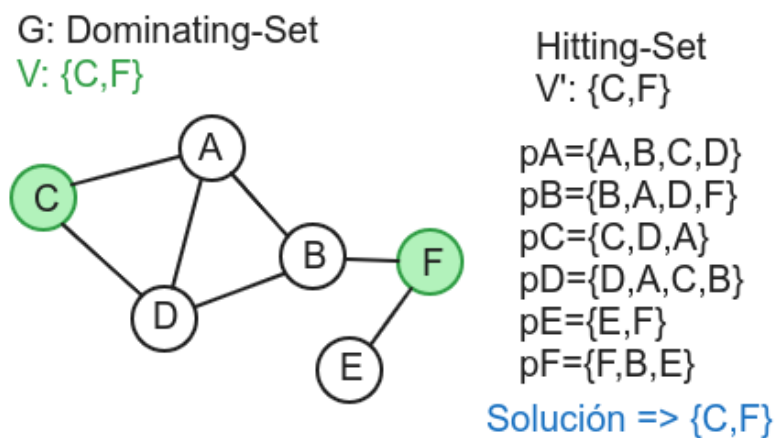


Figura 4: Ejemplo 2 de reducción de Dominating-Set a Hitting Set

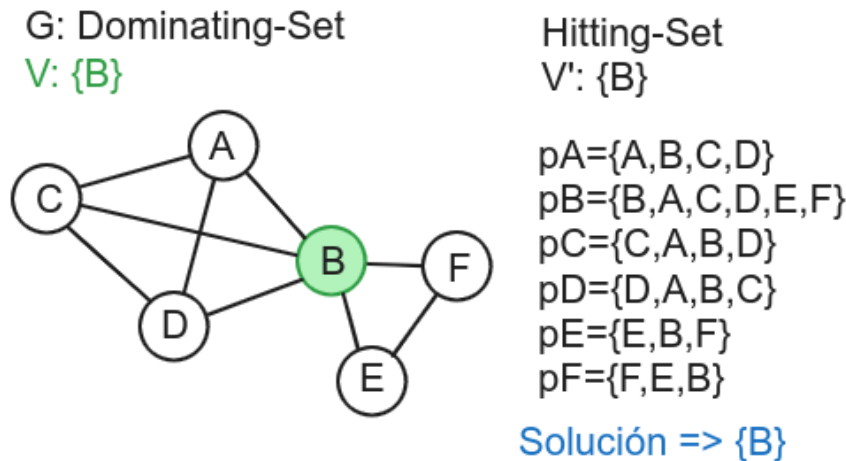


Figura 5: Ejemplo 3 de reducción de Dominating-Set a Hitting Set

En los tres casos analizados, se evidencia que la solución derivada del problema Hitting-Set representa la solución óptima para el Dominating-Set.

Finalmente:

$$\begin{array}{ccc}
 \text{Vertex-Cover} \leq_p \text{Dominating-Set} & \xrightarrow{\text{por transitividad}} & \text{Vertex-Cover} \leq_p \text{Hitting-Set} \\
 \text{Dominating-Set} \leq_p \text{Hitting-Set} & & \\
 \Rightarrow & & \text{Hitting-Set} \in \text{NP-Completo}
 \end{array}$$

3.3. Reducción Set-Cover a Hitting-Set

- Set-Cover: Dado un conjunto finito U y una familia $S = S_1, S_2, \dots, S_n$ de subconjuntos de U , el problema de Set Cover consiste en identificar el menor número de conjuntos cuya unión aún contiene todos los elementos del universo.

La reducción $\text{Set-Cover} \leq_p \text{Hitting-Set}$ consta en lo siguiente: Dado un grafo G de n vértices del problema Set-Cover, para cada elemento e_i del subconjunto S_i , se construye un conjunto E_i en el cual sus elementos van a ser cada S_j en el cual está incluido.

El análisis de la complejidad del problema del Set Cover se establece en $O(N \times U)$, donde N representa la cantidad de subconjuntos en S y U la cantidad de elementos presentes en el universo. Este costo surge de la necesidad de recorrer cada subconjunto S_i en la familia S y sus elementos correspondientes, operación que, en el peor de los casos, implica recorrer conjuntos de igual tamaño al universo. Luego, en cada subconjunto nuevo E_i proveniente del elemento e_i se le agrega el S_i donde está incluido, siendo esta una operación constante.

De esta manera, realizamos operaciones polinomiales para transformar nuestro problema de Set-Cover a Hitting-Set. Además, al igual que la reducción de Dominating Set a Hitting Set, esta reducción se caracteriza por ser de equivalencia simple ya que el resultado devuelto por el algoritmo de Hitting Set coincide directamente con los resultados esperados por el algoritmo de Set-Cover.

$$\text{Dominating-Set} \leq_p \text{Hitting-Set}$$

3.3.1. Ejemplos:

Set-Cover	Hitting-Set
$V=\{S1,S2\}$	$V'=\{S1,S2\}$
$S1=\{e1,e2,e4\}$	$E1=\{S1,S2,S3\}$
$S2=\{e1,e3,e4\}$	$E2=\{S1,S4\}$
$S3=\{e1,e4\}$	$E3=\{S2,S4\}$
$S4=\{e2,e3,e4\}$	$E4=\{S1,S2,S3,S4\}$
Solución $\Rightarrow \{S1,S2\}$	

Figura 6: Ejemplo 1 de reducción de Set-Cover a Hitting Set

Set-Cover	Hitting-Set
$V=\{S1,S3\}$	$V'=\{S1,S3\}$
$S1=\{e1,e3\}$	$E1=\{S1,S2,S4\}$
$S2=\{e1\}$	$E2=\{S3,S4\}$
$S3=\{e2,e4\}$	$E3=\{S1\}$
$S4=\{e1,e2,e4\}$	$E4=\{S3,S4\}$
Solución $\Rightarrow \{S1,S3\}$	

Figura 7: Ejemplo 2 de reducción de Set-Cover a Hitting Set

Al igual que la reducción de Dominating-Set a Hitting-Set, en los dos casos analizados, se evidencia que la solución derivada del problema Hitting-Set representa la solución óptima para el problema de Set-Cover.

4. Solución por backtracking

Para poder plantear el algoritmo de backtracing procedimos a seguir el esquema proporcionado por la cátedra:

1. Pruebo si la solución parcial es solución y es mejor que la actual encontrada:
 - a) Si lo es, actualizo la solución actual y la devuelvo
 - b) Si no lo es, avanzo si puedo

2. Pruebo si la solución parcial es potencial solución óptima
 - a) Si no lo es, retrocedo y vuelvo a 3)
 - b) Si lo es, llamo recursivamente y vuelvo a 1)
3. Prosigo explorando la solución parcial llamando recursivamente

Para la solución por backtracking consideramos relevantes las siguientes variables:

- Los subconjuntos B_i
- Solución parcial
- La solución actual óptima
- El índice (i_b) del subconjunto B_i en cuestión.

En cada instancia recursiva del algoritmo, se inicia con la evaluación del índice i_b para verificar si coincide con la cantidad total de subconjuntos B . Se emplea esta medida para garantizar la presencia de al menos un jugador de cada conjunto incluido en la solución parcial. En caso de ser igual y si la cardinalidad de la solución parcial es inferior a la solución actual, esta es considerada la nueva solución óptima (actual).

En caso contrario, se procede a descartar la solución parcial únicamente si su cardinalidad es mayor o igual que el de la solución actual. En este escenario, se implementa la técnica de backtracking, regresando al llamado anterior y desechando la exploración de esta rama de solución.

En el caso específico en el que la solución parcial no es compatible pero aún puede representar una solución óptima potencial, se lleva a cabo una verificación adicional. Se examina el subconjunto B_i (donde $i = i_b$) para garantizar la inclusión de al menos un jugador en la solución final. Si este requisito no se cumple, se procede a evaluar individualmente la inclusión de cada jugador presente en B_i para determinar cuál de ellos conduce a la obtención de la solución óptima.

Además, se implementó una poda adicional de gran alcance. En esta etapa, donde se examina cada jugador para determinar cuál contribuye a la solución óptima, solo se exploran aquellos que no han sido considerados previamente por los conjuntos B_j donde $j < i_b$. Esta última poda se tuvo en cuenta considerando lo siguiente: Suponiendo que se tiene $B_i = e_1, e_2$ en el nivel i_b , si ya se evaluaron las alternativas con e_1 , no tiene sentido revisar luego las alternativas en los conjuntos $B_k, k > i_b$ con e_2 que incluyan e_1 porque:

1. Para que eso tenga sentido, $e_1 + e_2$ debe ser una alternativa superior que sólo e_1 y sólo e_2 .
2. Si e_2 ya se estaba teniendo en cuenta en un nivel anterior $B_j, j < i_b$, ya se consideró $e_1 + e_2$, por lo cual incluso en B_i no tiene sentido que se considere e_2 (ni antes e_1 , el set estaba cubierto).
3. La consideración de que $e_1 + e_2$ es una opción superior ya fue abordada al analizar e_1 . Esto implica que ya se habría encontrado un conjunto que incluya a e_2 sin además ningún otro elemento incluido en la solución parcial. Para que $e_1 + e_2$ sea una mejor alternativa, al menos un conjunto $B_k, k > i_b$ debe contener a e_2 . Esto demuestra que esta alternativa ya fue contemplada al evaluar e_1 en B_i .

```
1 def backtracking_HSP(b_array: list, sol_parcial: set, sol_actual, i_b, propuestos:
2     set):
3     if i_b >= len(b_array):
4         if sol_actual == None or len(sol_parcial) < len(sol_actual):
5             return sol_parcial.copy()
6             return sol_actual
7
8     if sol_actual != None and len(sol_parcial) >= len(sol_actual):
9         return sol_actual
```

```
10     if esta_incluido(b_array[i_b], sol_parcial):
11         return backtracking_HSP(b_array, sol_parcial, sol_actual, i_b+1, propuestos
12     )
13     propuestos_b_array = set()
14
15     for jugador in b_array[i_b]:
16         if jugador in propuestos:
```

5. Solución por Programación Lineal

5.1. Programación Lineal Entera

También se puede reducir Hitting-Set Problem a Programación Lineal Entera de la siguiente manera:

1. Para cada elemento i del universo U , se crea una variable y_i que puede tomar los valores 0 o 1.
2. Se define una función $f_j = \sum_{e \in S_j} e$ para cada conjunto S_j , y se establece una restricción que acota a f_j en el rango $1 \leq f_j \leq |S_j|$.
3. El objetivo radica en minimizar la función $f = \sum_{i=0}^n y_i$.

Luego, el conjunto solución C será

$$C = \{e_i \in U \mid y_i = 1\}$$

La complejidad de esta reducción es $O(N \times U)$ ya que se debe recorrer todos los subconjuntos B_i y, por cada uno, recorrer cada elemento. Este proceso es polinomial, y la complejidad de Programación Lineal Entera es exponencial.

$$\text{Hitting-Set} \leq_p \text{Programación Lineal Entera}$$

El código de la reducción es el siguiente:

```
1 def hitting_set_pl_entera(b_array):
2     problem = pulp.LpProblem("Scaloni", pulp.LpMinimize)
3     dic_jugadores = {}
4
5     for periodista in range(len(b_array)):
6         set_p = set()
7         for jugador in b_array[periodista]:
8             y = None
9             if jugador in dic_jugadores:
10                 y = dic_jugadores[jugador]
11             else:
12                 y = pulp.LpVariable(f"y_{jugador}", cat=pulp.LpBinary)
13                 dic_jugadores[jugador] = y
14                 set_p.add(y)
15
16         p = pulp.lpSum(set_p)
17         problem += p >= 1
18         problem += p <= len(set_p)
19
20     z = pulp.lpSum(dic_jugadores.values())
21     problem += z
22
23     pulp.LpSolverDefault.msg = 0
24     problem.solve()
25
```

```
26 # Obtener jugadores seleccionados
27 jugadores_seleccionados = [
28     jugador for jugador, valor in dic_jugadores.items() if pulp.value(valor) >
    0]
```

5.2. Aproximación por Programación Lineal Continua

Otra estrategia para abordar la solución del Hitting-Set Problem implica el enfoque de la Programación Lineal continua. Esta aproximación se asemeja a la reducción previamente descrita, con la distinción fundamental de que las variables y_i pueden asumir valores reales dentro del intervalo 0 a 1.

Posteriormente, se lleva a cabo una consideración respecto a estos valores, donde aquellos que excedan el umbral del $1/b$, siendo b el cardinal máximo de todos los conjuntos S_j , son incluidos como componentes de la solución final.

Luego, el conjunto solución C será

$$C = \left\{ e_i \in U \mid y_i \geq \frac{1}{b} \right\}$$

Por la mismas consideraciones aplicadas en la reducción de la Programación Lineal Entera, la complejidad asociada a la reducción de la Programación Lineal Continua al Hitting Set es de $O(N \times U)$. Sin embargo, la complejidad de Programación Lineal Continua es $O(n^9)$ lo cual es polinomial, a diferencia de la Entera.

El código de la reducción es el siguiente:

```
1 def hitting_set_pl_entera(b_array):
2     problem = pulp.LpProblem("Scaloni", pulp.LpMinimize)
3     dic_jugadores = {}
4
5     for periodista in range(len(b_array)):
6         set_p = set()
7         for jugador in b_array[periodista]:
8             y = None
9             if jugador in dic_jugadores:
10                 y = dic_jugadores[jugador]
11             else:
12                 y = pulp.LpVariable(f"y_{jugador}", cat=pulp.LpBinary)
13                 dic_jugadores[jugador] = y
14                 set_p.add(y)
15
16         p = pulp.lpSum(set_p)
17         problem += p >= 1
18         problem += p <= len(set_p)
19
20     z = pulp.lpSum(dic_jugadores.values())
21     problem += z
22
23     pulp.LpSolverDefault.msg = 0
24     problem.solve()
25
26     # Obtener jugadores seleccionados
27     jugadores_seleccionados = [
28         jugador for jugador, valor in dic_jugadores.items() if pulp.value(valor) >
        0]
29
30     return jugadores_seleccionados
```

Con el objetivo de evaluar qué tan buena aproximación es la Programación Lineal Continua respecto a la Programación Lineal Entera, se propuso el siguiente escenario que resalta las diferencias entre las soluciones obtenidas por ambos algoritmos:

Consideramos dos conjuntos que representan medios diferentes, denominados set1 y set2. Estos conjuntos se componen de la siguiente manera:

1. set1 con tamaño b , expresado como $set_1 = x_1, x_2, \dots, x_{b-1}, x_b$
2. set2 con tamaño $b - 1$, representado como $set_2 = x_1, x_2, \dots, x_{b-1}$

En un contexto de Programación Lineal Continua (PLC), una solución posible puede ser la asignación $x_1 = x_2 = \dots = x_{b-1} = 1/(b-1)$ y $x_b = 0$.

En esta situación, dado que $\frac{1}{b} < \frac{1}{b-1}$, las variables del set_2 , al ser redondeadas, resultarían en 1, siendo todas incluidas en la solución final.

Por otro lado, la solución proporcionada por la Programación Lineal Entera (PLE), que representa la solución óptima, presentaría, por ejemplo, la siguiente asignación de valores: $x_1 = 1$ y $x_2 = \dots = x_b = 0$.

No obstante, al obtenerse una aproximación mediante PLC que establece $x_1 = x_2 = \dots = x_{b-1} = 1$ se deriva la siguiente relación de aproximación: $r(A) = \frac{A(I)}{z(I)} = \frac{b-1}{1}$

En consecuencia, $b - 1$, se establece como una cota superior de la aproximación.

6. Aproximación por Greedy

Proponemos dos aproximaciones extra.

6.0.1. Máximo por grupo

Este enfoque realiza un cálculo de la frecuencia con la que cada jugador aparece en los m subconjuntos B . Posteriormente, procede a recorrer cada uno de estos subconjuntos y, si la solución parcial propuesta no incluye ningún jugador presente en un subconjunto dado, se incluye en esta solución al jugador que tiene la mayor frecuencia de apariciones dentro de dicho subconjunto.

Este algoritmo sigue la técnica de diseño greedy al enfocarse en optimizar la solución global mediante la búsqueda de óptimos locales en cada subconjunto. Se prioriza la inclusión del jugador con la mayor frecuencia de aparición en situaciones donde la solución parcial no incluye a ningún jugador del subconjunto evaluado. Este método busca mejorar la solución global al introducir jugadores de acuerdo con su frecuencia de aparición en los subconjuntos, maximizando así la cobertura de conjuntos dentro de la solución propuesta.

```
1  return: solucion
2  """
3  # contamos la cantidad de apariciones de cada jugador por cada prensa
4  apariciones = {}
5  for subconjunto in subconjuntos: # 0(len(subconjuntos)*len(subconjunto))
6      for jugador in subconjunto:
7          if jugador in apariciones:
8              apariciones[jugador] += 1
9          else:
10             apariciones[jugador] = 1
11
12 # ordenamos los subconjuntos por cantidad de apariciones de cada jugador
13
14 # obtenemos la solucion mediante el optimo local
15 solucion = set()
16 for subconjunto in subconjuntos: # 0(len(subconjuntos)*len(subconjunto))
17     aparicion_max = None
18     for jugador in subconjunto:
19         if jugador in solucion:
20             aparicion_max = jugador
21             break
22
23     else:
24         if aparicion_max is None or apariciones[jugador] > apariciones[
25             aparicion_max]:
26             aparicion_max = jugador
```

```
27     solucion.add(aparicion_max)
28
29     return solucion
30
31
32 def aproximacion_greedy_maximo_global_con_recalculo(subconjuntos: list):
33     """
```

La primera operación tiene complejidad $O(b \times m)$, con b el cardinal máximo de jugadores por subconjunto y m la cantidad de subconjuntos totales. Con grupos más chicos, el algoritmo tiende a lineal ($O(m)$) y con grupos más grandes, a $O(b \times m)$. De la misma manera, la segunda operación tiene complejidad de $O(b \times m)$ ya que por cada subconjunto ($O(m)$) se deben recorrer todos sus jugadores para verificar si efectivamente están en la solución final ($O(b)$) y, en caso de que no esté ninguno, se debe encontrar el jugador con máximas apariciones ($O(1)$) (esta operación se va contemplando a medida que se verifica la anterior condición). De esta manera, la complejidad total es $O(2(b \times m)) = O(b \times m)$ y resulta polinomial.

6.0.2. Máximo global con recálculo

La segunda estrategia inicia de manera similar, llevando a cabo el cálculo de la frecuencia de aparición de cada jugador en los diferentes subconjuntos. Posteriormente, se procede a añadir a la solución el jugador que presenta la mayor cantidad de apariciones entre todos, y quita las apariciones de los subconjuntos que ya cubre al resto de los jugadores. Este proceso se repite sucesivamente hasta quedarse sin jugadores restantes o hasta que el jugador con la mayor frecuencia encontrada no tenga más apariciones restantes.

La técnica de diseño empleada en este algoritmo, al igual que el anterior explicado, se caracteriza por ser greedy, ya que busca optimizar la solución al priorizar la inclusión del jugador con la mayor frecuencia en cada iteración, hasta alcanzar la cobertura total de todos los subconjuntos.

```
1     param subconjuntos: subconjuntos de jugadores pedidos por cada prensa
2     return: solucion
3     """
4     # contamos la cantidad de apariciones de cada jugador por cada prensa
5     apariciones = {}
6     # O(len(subconjuntos)*len(subconjunto))
7     for index, subconjunto in enumerate(subconjuntos):
8         for jugador in subconjunto:
9             if jugador not in apariciones:
10                 apariciones[jugador] = set()
11                 apariciones[jugador].add(index)
12
13     # obtenemos la solucion mediante el optimo local
14     solucion = set()
15
16     while len(apariciones) != 0: # O(len(jugadores)*len(subconjuntos)*len(
17         jugador, index_subconjuntos = max(apariciones.items(
18             ), key=lambda jugador_index_subconjuntos: len(jugador_index_subconjuntos
19             [1]))
20         apariciones.pop(jugador)
21         if len(index_subconjuntos) == 0:
22             break
23         solucion.add(jugador)
24
25     # O(len(subconjuntos)*len(subconjunto))
26     for index_subconjunto in index_subconjuntos:
27         for jugador_companiero_de_conjunto in subconjuntos[index_subconjunto]:
28             if jugador != jugador_companiero_de_conjunto:
29                 apariciones[jugador_companiero_de_conjunto].remove(
30                     index_subconjunto)
```

La complejidad de la primera operación es $O(b \times m)$. La segunda tiene complejidad $O(b \times m \times n)$, con j la cantidad de jugadores de la solución, $j \leq m$, y g la cantidad de grupos que cubre cada jugador $g \leq n$. Entonces, la complejidad total es $O(k \times m + j \times g \times m)$.

7. Ejemplos

A continuación, compararemos los resultados obtenidos por cada uno de los algoritmos con distintos ejemplos.

El primer ejemplo, ilustrado en la fig. 8, es un caso feliz en el que los tres algoritmos obtienen el resultado óptimo.




Figura 8: Ejemplo 1




Figura 9: Ejemplo 1 resuelto por Máximo por grupo




Figura 10: Ejemplo 1 resuelto por Máximo global con recálculo

El segundo ejemplo (fig. 11) podemos observar en la fig. 12 que "Máximo por grupo", de menor complejidad, no encuentra la solución óptima, pero el "Máximo global con recálculo", en la fig. 13, sí.




Figura 11: Ejemplo 2




Figura 12: Ejemplo 2 resuelto por Máximo por grupo




Figura 13: Ejemplo 2 resuelto por Máximo global con recálculo

Por último, en el ejemplo de la fig. 14, tanto "Máximo por grupo" (fig. 15) como "Máximo global con recálculo" (fig. 16) no llegan a la solución óptima.




Figura 14: Ejemplo 3

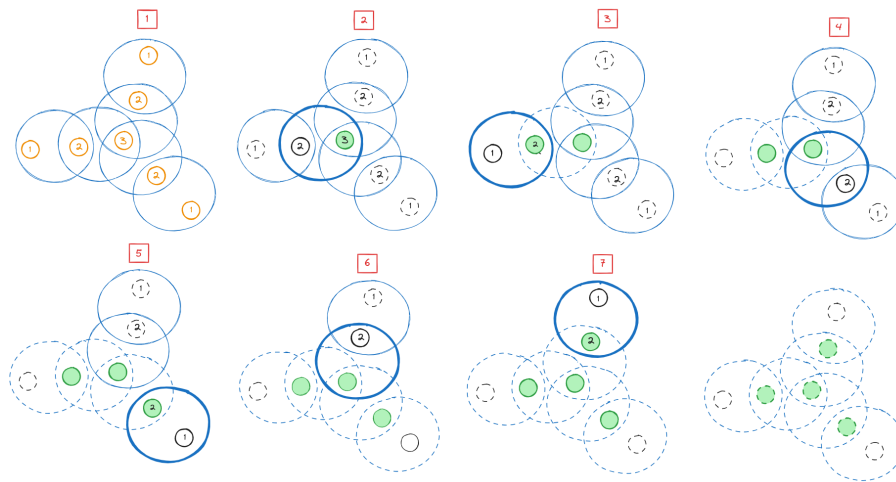


Figura 15: Ejemplo 3 resuelto por Máximo por grupo




Figura 16: Ejemplo 3 resuelto por Máximo global con recálculo

8. Mediciones

Para las mediciones, creamos subconjuntos de dos tipos distintos. Uno que lo llamamos *jugadores* y otro que lo llamamos *abecedario*. El primero contiene una lista con subconjuntos de jugadores de fútbol argentino, mientras que el segundo contiene una lista con subconjuntos de combinaciones de letras del abecedario. Esto debido a que queríamos obtener comportamientos menos

repetitivos, ya que tenemos un máximo de 43 jugadores distintos, mientras que el abecedario tiene 26 letras, y en base a ellas, podemos hacer combinaciones de letras para generar "palabras" de distintos tamaños, los cuales se repetirán en menor medida. Con ello conseguimos obtener resultados más amplios (no es lo mismo un conjunto de 1 millón de elementos distintos con una solución de Hitting Set hasta de 43 elementos, a una solución con 1 millón de elementos distintos).

Además, notamos que los procesos de fondo del sistema nos generaba distorsiones en los tiempos de ejecución de una misma muestra. Resolvimos este problema realizando varias mediciones para el mismo escenario de subconjuntos y tomando el promedio de los tiempos obtenidos. Esta estrategia nos permitió abordar otro problema significativo: el orden en el que se evalúan los jugadores en cada subconjunto adquiere una importancia relevante en el rendimiento final del algoritmo. Esto depende especialmente de la frecuencia con la que cada jugador aparece en los demás subconjuntos.

Asimismo, al definir arbitrariamente cada escenario, puede ocurrir que en una cantidad x de subconjuntos, los jugadores incluidos en cada uno sean considerablemente diferentes o poco comunes, lo que representa un caso desfavorable. En contraste, en una cantidad de conjuntos $x + 1$, podría darse una situación mucho más favorable, con una mayor similitud entre los jugadores incluidos en cada conjunto. Esto puede llevar a una diferencia significativa en los tiempos de ejecución, a pesar de que la cantidad de conjuntos varíe en una sola unidad.

Siguiendo las estrategias explicadas, realizamos mediciones variando solamente la cantidad de subconjuntos y comparando el tiempo de ejecución de los diferentes algoritmos analizados a lo largo del informe: Backtracking, algoritmo Greedy Máximo por grupo, algoritmo Greedy Máximo global con recálculo, Programación Lineal Entera y Programación Lineal Continua.

Al evaluar los algoritmos con orden teórico exponencial, Backtracking y Programación Lineal Entera, podemos corroborar a través de los gráficos una clara tendencia al aumento significativo en el tiempo de ejecución conforme se incrementa la cantidad de subconjuntos, en comparación con otros algoritmos, especialmente los que emplean el método Greedy.

La gráfica de nuestra implementación de Backtracking confirma su comportamiento exponencial, concordando con su cota teórica. Por otro lado, el algoritmo de Programación Lineal Entera, contrario a lo esperado, presenta una gráfica más cercana a una función lineal, asemejándose en tiempo de ejecución con el algoritmo de Programación Lineal Continua. Esto se debe a las optimizaciones implementadas en la librería *pulp* utilizada para su ejecución, las cuales reducen significativamente su tiempo de ejecución en comparación con su complejidad teórica. Es importante mencionar que la visualización de una curva exponencial en este algoritmo solo ocurre en situaciones donde las optimizaciones no influyen de manera considerable.

Por otro lado, podemos observar que la curva de Programación Lineal Continua se asemeja a una curva polinómica. De esta manera, mediante el gráfico y la validación a través del error cuadrático medio, hemos comprobado que la curva de un polinomio de grado 9?? se adapta de manera más precisa a nuestros datos, corroborando la cota teórica. De esta forma pudimos comprobar empíricamente que la complejidad tiende a $O(n^9)$.

En el siguiente gráfico, se ilustra el grado de aproximación, variando b (Figura 1) y manteniéndola constante (Figura 2). Para poder corroborar nuestra cota máxima de aproximación, hicimos variar este parámetro b en un intervalo desde [25 : 30]. Como en la gráfica se puede observar que la peor aproximación es NUM_{MAX} , luego se comprueba que la cota máxima es efectivamente en cada escenario es $b - 1$.

Por otra parte al examinar los algoritmos que emplean la estrategia de diseño Greedy, ambos siguen una tendencia polinomial. En el primer gráfico, se observa que el RMSE presenta un menor valor en la regresión lineal. Esto se debe a que la variable b permanece constante para cada escenario, variando únicamente la cantidad de subconjuntos (m). En contraste, al aumentar la variable b a medida que se aumenta la cantidad de subconjuntos, se puede visualizar su tendencia polinómica no lineal, evidenciando la cota teórica.

Asimismo, se destaca una marcada diferencia en los tiempos de ejecución entre el algoritmo Greedy Máximo por grupo y el algoritmo Greedy Máximo global. El primero muestra una ejecución significativamente más rápida en todos los escenarios comparado con el segundo. Sin embargo, al

analizar las soluciones obtenidas, se evidencia que el algoritmo Greedy Máximo global se acerca más a la solución óptima en todos los casos estudiados.

Esta divergencia plantea una dificultad al momento de decidir cuál enfoque es más adecuado. Por un lado, el algoritmo por grupo se destaca por su eficiencia temporal, ofreciendo tiempos de ejecución notoriamente inferiores y, por otro lado, el enfoque global muestra una mayor aproximación a la solución óptima.

!!! INSERTAR GRAFICOS !!!

9. Conclusiones

Finalmente, consideramos que la solución más adecuada para abordar la problemática presentada por Scaloni sería a través del empleo de técnicas como Backtracking o Programación Lineal Entera, siempre y cuando el número de medios no sea excesivamente alto.

No obstante, en situaciones que involucren conjuntos de medios considerablemente extensos, las aproximaciones obtenidas a través de algoritmos como los métodos greedy o la Programación Lineal pueden ofrecer una alternativa viable para obtener resultados en tiempos reducidos. Sin embargo, se debe tener en cuenta que, si bien estas soluciones pueden ser efectivas en términos de eficiencia computacional, pueden distanciarse significativamente de la solución óptima. Este fenómeno es particularmente notable en el caso de la Programación Lineal, la cual representa una $(b-1)$ -Aproximación (siendo b el número máximo de elementos en los conjuntos de medios), siendo una diferencia significativa respecto a la solución óptima.